

Renato Pedrosa Vasconcelos

rpv@cin.ufpe.br

RECIFE/2025

Plano de Projeto Experimental: Plataforma de Dados para Manutenção Preditiva e Otimização de Ativos Industriais

1. Título do Projeto

SENTINELA: Sistema de Monitoramento Preditivo e Otimização de Ativos Baseado em IoT e Analytics em Tempo Real.

2. Área Tecnológica Predominante

Engenharia de Dados (Data Engineering) e Analytics Industrial (Industrial AI).

3. Problema/Oportunidade Tecnológica

Problema: As indústrias de manufatura contínua (ex.: química, papel e celulose, mineração) frequentemente operam com base em manutenção corretiva ou calendários fixos de manutenção preventiva. Isso resulta em:

- Paradas Não Programadas: Custos elevados devido à interrupção da produção.
- Troca Prematura de Peças: Desperdício de recursos e vida útil residual não aproveitada.
- Falta de Visibilidade Proativa: Incapacidade de prever falhas baseando-se na condição real do equipamento.

Oportunidade: A convergência de IoT (Sensores e PLCs), Big Data e Machine Learning permite a criação de uma plataforma de dados que transforma dados brutos de vibração, temperatura, corrente e pressão em insights acionáveis. A oportunidade é implementar uma solução de Manutenção Preditiva que antecipe falhas e otimize o tempo de vida dos ativos, reduzindo custos e aumentando a disponibilidade operacional.

4. Objetivos

Objetivo Geral:

Desenvolver e implementar uma plataforma escalável de engenharia de dados para aquisição, processamento e análise de dados industriais, capaz de detectar anomalias e prever falhas em equipamentos críticos (ex.: bombas, motores, ventiladores), com uma antecipação mínima de 14 dias.

Objetivos Específicos:

1. Projetar e construir uma arquitetura de dados em nuvem (ex.: AWS, Azure) para ingestão de dados de sensores IoT em tempo real e dados históricos de sistemas SCADA e CMMS.
2. Desenvolver *pipelines* de dados (ETL/ELT) robustos para limpeza, normalização e enriquecimento dos dados brutos.
3. Implementar um modelo de Machine Learning (ex.: Regressão, Séries Temporais, Classificação) para prever a Remaining Useful Life (RUL - Vida Útil Remanescente) de componentes específicos.
4. Criar um dashboard interativo (Painel de Controle) para visualização do estado de saúde dos ativos, alertas de anomalias e recomendações de manutenção.
5. Validar a plataforma em um ambiente piloto, utilizando dados de pelo menos dois ativos críticos de uma planta industrial.

5. Metodologia

A metodologia será baseada no framework CRISP-DM (Cross-Industry Standard Process for Data Mining), adaptado para projetos de engenharia de dados:

1. Compreensão do Negócio: Entrevistas com equipes de manutenção e operação para identificar ativos críticos, modos de falha e KPIs desejados (ex.: MTBF - Mean Time Between Failures).
2. Compreensão dos Dados: Catalogação de fontes de dados (sensores, históricos de manutenção, ordens de serviço). Análise exploratória de dados (EDA) para identificar ruídos, missing data e correlações.
3. Preparação dos Dados (Engenharia de Dados):
 - Ingestão: Uso de serviços como AWS IoT Core ou Azure IoT Hub para coleta de dados de sensores. Uso de

- connectors (ex.: Apache Kafka, AWS Kinesis) para dados em tempo real.
 - Processamento: Utilização de frameworks como Apache Spark (ex: com Databricks ou AWS EMR) para limpeza, agregação e transformação dos dados em lote e streaming.
 - Armazenamento: Armazenamento em data lake (ex.: Amazon S3, Azure Data Lake Storage) em formato colunar (Parquet) para economia e performance. Dados processados serão carregados em um data warehouse (ex.: Amazon Redshift, Snowflake) para análise.
4. Modelagem (Data Science):
 - Desenvolvimento de modelos de detecção de anomalias (ex.: Isolation Forest, Autoencoders).
 - Treinamento de modelos de previsão de RUL usando algoritmos de séries temporais (ex.: Prophet, LSTM).
 - Experimentação e validação dos modelos usando métricas como MAE (Mean Absolute Error) e F1-Score.
 5. Implementação e Deployment:
 - Os modelos serão empacotados e disponibilizados como APIs via AWS SageMaker ou Azure ML.
 - Os *pipelines* de dados serão orquestrados com ferramentas como Apache Airflow ou Azure Data Factory.
 6. Monitoramento e Manutenção: Implementação de monitoramento da saúde dos *pipelines* e do desempenho dos modelos (conceito de MLOps), garantindo a confiabilidade do sistema.

6. Cronograma (12 Semanas)

Fase / Atividade	Semana s 1-2	Semana s 3-6	Semana s 7-9	Semana s 10-12
Fase 1: Planejamento e Discovery	X			

Definição de Requisitos e Arquitetura	X			
Fase 2: Engenharia de Dados	X	X		
Implementação do Data Lake e Pipelines de Ingestão	X			
Processamento e Modelagem de Dados (ETL/ELT)		X		
Fase 3: Data Science e Analytics	X	X	X	
Análise Exploratória e Desenvolvimento de Modelos	X	X		
Treinamento e Validação dos Modelos		X	X	
Fase 4: Visualização e Integração				X
Desenvolvimento do Dashboard e APIs				X
Fase 5: Validação e Documentação				X
Testes Piloto e Ajustes Finais				X

7. Resultados Esperados

- Redução de até 30% nas paradas não programadas dos ativos monitorados no piloto.
- Aumento de 15% na vida útil de componentes através da manutenção baseada em condição.
- Dashboard operacional em tempo real, acessível para as equipes de manutenção e operação.
- Sistema de alertas proativos com indicadores de saúde do ativo e probabilidade de falha.
- Documentação técnica completa da arquitetura e dos *pipelines*, permitindo a replicação do projeto para outros ativos.

8. Conexão com os Desafios das Áreas Temáticas

Este projeto se conecta diretamente aos desafios das áreas de Indústria 4.0 e Transformação Digital:

- Interoperabilidade e IIoT (Industrial Internet of Things): Integração de sensores heterogêneos e protocolos industriais (OPC UA, MQTT) em uma única plataforma.
- Analytics e Big Data: Processamento de grandes volumes de dados de séries temporais em alta velocidade para extração de inteligência.
- Manufatura Preditiva e Prescritiva: Não apenas prevê falhas, mas também orienta as ações de manutenção, evoluindo para um sistema prescritivo.
- Cibersegurança: A arquitetura em nuvem deve considerar a segurança dos dados desde a borda até o data center.
- Sustentabilidade: Aumento da eficiência energética e redução do desperdício de peças e materiais.

9. Entregas Previstas

1. Documento de Arquitetura de Dados: Detalhando a infraestrutura em nuvem e o fluxo de dados.
2. Código Fonte dos Pipelines de Dados: Scripts em PySpark/SQL orquestrados (ex.: no Airflow).
3. Modelo de Machine Learning Treinado e Empacotado: Disponível como uma API REST.
4. Dashboard Interativo (BI): Desenvolvido em ferramentas como Grafana, Power BI ou Tableau.
5. Relatório Técnico Final: Contendo metodologia, resultados da validação piloto, análise de ROI e plano de expansão.
6. Manual de Operação da Plataforma: Para a equipe de TI/Manutenção dar continuidade ao projeto.

10. Plano de Infraestrutura e Aquisições (Se Aplicável)

Item	Descrição	Justificativa
Serviços de Nuvem (AWS/Azure/GCP)	Conta para desenvolvimento e ambiente piloto. Recursos: Computação (EC2/VM), Storage (S3/ADLS), Banco de Dados (Redshift/Synapse), IoT Hub, Serviços de ML.	Fornece a base escalável, elástica e econômica para a construção da plataforma, eliminando a necessidade de investimento em hardware.
Sensores IoT Adicionais	Acelerômetros, sensores de temperatura e pressão, gateways de comunicação.	Necessário se os ativos piloto não possuírem sensoria adequada para coleta dos dados

		necessários para os modelos.
Ferramentas de DevOps/MLOps	Licenças para ferramentas como GitHub Actions, Docker, Kubernetes.	Para automação do deployment, versionamento de código e modelos (CI/CD), garantindo a robustez do projeto.
Consultoria Especializada (Opcional)	Contratação de especialista em séries temporais ou em um ativo específico crítico.	Pode acelerar o desenvolvimento e aumentar a precisão dos modelos em casos de alta complexidade técnica.

11 Referências

Livro sobre Arquitetura de Dados e Engenharia de Dados

Título: Fundamentals of Data Engineering: Plan and Build Robust Data Systems

Autores: Joe Reis e Matt Housley

Ano de Publicação: 2022

Editora: O'Reilly Media

Artigo Científico sobre Manutenção Preditiva e Machine Learning

Título: A Survey of Predictive Maintenance: Systems, Purposes and Approaches

Autores: Lei et al.

Ano de Publicação: 2021

Publicado em: IEEE Communications Surveys & Tutorials (Volume: 23, Issue: 3)

Link de Acesso (geralmente gratuito em universidades):

<https://ieeexplore.ieee.org/document/9517839>

